

Yelp 可疑評論者偵測

基於 Yelp Open Dataset 的無監督低可信度評論者偵測

1,987,841

總用戶數

3,439

標記用戶 (0.17%)

2

獨立偵測分支

無監督異常偵測 · Yelp Open Dataset · Side Project

Yelp 可疑用戶偵測

概述

針對 Yelp Open Dataset (1,987,841 名用戶) 的無監督異常偵測，不依賴標記資料。
從兩個完全獨立的維度出發，各自找到行為異常的帳號，再透過店家群聚分析確認協調行為。

分析架構

[資料庫]



分支一：時段 K-Means

設計理念

真實用戶的發評時段由作息與時區塑造，不會無緣無故集中在清晨。

Yelp 以用戶本地時間儲存時間戳 (實證：PA 用戶發評高峰 = 18:00 美東時間)，因此早晨異常代表本地時間的真實偏離。

特徵建構

每位用戶 → **24 維概率向量** (小時發評比例)

- 按年歸一化後加總，再次歸一化，消除年份差異
- ≥ 5 則評論的用戶才進入分析，共 **287,000** 人

聚類與可疑群識別

MiniBatchKMeans ($K=20$)，以熵和**早晨比例 (06:00–11:59) **評估各群。

可疑群	早晨比例	特徵
Cluster 10	顯著偏高	正常清醒時段接近零
Cluster 19	顯著偏高	同上

交叉驗證：計算各子群用戶所評店家的營業時間熱力圖

- C10-Sub3 ($n=420$)：早晨評論中只有 **9%** 落在店家已開業時段 (正常群：43%)
- C10-Sub4 ($n=357$)：早晨評論中只有 **14%** 落在店家已開業時段

全體評分

以 Sub3+Sub4 建立異常中心點，對全體 287k 用戶算餘弦相似度。

門檻 = 已知異常用戶分數的第 5 百分位數 (**0.546**)，得到 **4,037** 名候選人 (1.4%)。

K1 Tier-2 衍生驗證

4,037 名 K1 候選人中，只有 **9** 人與 Lifetime 除名清單重疊——兩條路線幾乎正交。

剩餘 **4,028** 名純 **K1** 用戶，以相同的店家群聚邏輯再驗證：

- 45 家店家出現協調刷評 ($\text{span} < 7d$) → **78** 人確認，納入除名清單
 - 沒有任何店家達到 $\text{suspicion_score} \geq 0.5$
 - 對應的 closed_pct 分析： $\text{mean} = 0.847$ (正常用戶 0.721)，確認早晨異常為真實偏離，不是時區干擾
-

分支二：帳號生命週期 K-Means

設計理念

無論時區，可疑帳號的行為會集中在帳號生命的某個時間點：

- **單評論**：創號後只發一則評論，消失
- **爆發後消失**：創號後短時間密集發評，之後沉默

全局歸一化

$$\text{position} = (\text{評論日期} - \text{帳號創立日期}) / \text{全局最大間距} (\approx 6,241 \text{ 天})$$

所有用戶映射到共同的 $[0, 1]$ 軸，消除加入時間不同的影響。

單評論用戶 ($n = 1,135,945$)

一則評論的用戶以 50 格 one-hot 向量聚類。

關鍵發現：Cluster 1 ($n=320,060$)， $\text{mean position} \approx 0.003$

→ 28% 的單評論用戶在帳號創立後 19 天內發出唯一評論，之後消失。

多評論用戶 ($n = 851,896$)

50 格概率向量，MiniBatchKMeans ($K=20$)，以熵評估。

群	熵	峰值位置	意義
Cluster 1 ($n=91,597$)	0.31	0.00	最典型的爆發後消失

爆發群定義： $\text{peak_position} \leq 0.10$ 且 $\text{entropy} < 2.0$

→ Cluster 1、5、7、9、14，共 217,641 人

店家群聚與時間集中度

核心邏輯

高覆蓋率 + 短時間窗口 = 協調刷評

高覆蓋率但分散多年 = 自然累積 (非信號)

指標

指標	定義
coverage_rate	可疑用戶數 / 該店家總評論數
span_days	最早至最晚一筆可疑評論的間距 (天)
dense_30d_pct	可疑評論中落在最密集 30 天窗口的比例
suspicion_score	coverage_rate × dense_30d_pct

協調確認門檻： `span_days < 7`
高重疊門檻： `suspicion_score ≥ 0.5` (覆蓋率與時間集中度同時 ≥ 50%)

最終結果

資料集總用戶： **1,987,841** 人
輸出： `lifetime kmeans/result/final/removal_final.parquet`

類別	人數	佔比	判定條件
協調刷評 (單評論)	1,424	0.072%	≥ 2 個可疑帳號評同一店家，span < 7d
協調刷評 (爆發型)	744	0.037%	同上
單評論高店家重疊	1,193	0.060%	suspicion_score ≥ 0.5
K1 協調	78	0.004%	K1 候選人 + 店家協調 span < 7d
合計	3,439	0.173%	

回頭驗證：方法論獨立性

`verify/scripts/verify_all.py` 將 3,439 名 flagged 用戶放回所有分析維度。

指標	數值
出現在 K1 空間的 flagged 用戶	514 / 3,439 (15%)
這 514 人的平均餘弦相似度	0.168 (K1 門檻 = 0.546)
在 Lifetime 單評論系統	2,617 人 (76%)
closed_pct : 正常用戶 mean	0.721
closed_pct : flagged mean	0.740 ($\Delta = +0.018$)

核心發現：flagged 用戶在「不是因此被抓」的維度上，與正常用戶幾乎無異。這不是循環論證的問題——恰恰相反，**正交性證明每條路線偵測的是真正不同的底層行為**：

類別	行為模式	推斷動機
single_coordinated	多帳號 7 天內評同一店，消失	受僱一次性刷評
burst_coordinated	帳號早期爆發後沉默，共享目標店家	批量刷評或收購帳號
single_high_overlap	所評店家被可疑帳號高度覆蓋	刷評生態圈的參與者
k1_coordinated	系統性早晨發評 + 共享目標店家	自動化腳本或遠端操控


門檻選擇依據

門檻	選擇理由
MIN_SUSPECT_USERS = 2	兩個一次性帳號在 7 天內獨立評同一家小店，機率本就極低；要求 3 個會錯失大量真實協調行為
span_days < 7	3 天內 = 近乎確定的協調；7 天仍難以被自然流量解釋；14 天後口碑傳播成為合理替代解釋
suspicion_score ≥ 0.5	覆蓋率與時間集中度同時過半，單一條件不構成信號
爆發型帳號不直接除名	217,641 人的生命週期模式異常，但高活躍真實用戶特徵相同；只有 744 人有直接協調證據才納入


偵測信號總覽

信號	分支	強度
早晨發評比例異常 (本地時間)	時段 K-Means	強；已以店家營業時間交叉驗證
評論時間 vs 店家營業時間不符	時段 K-Means	時區無關，獨立佐證
餘弦相似度 (全體 287k)	時段 K-Means	將異常推廣至全體用戶
K1 候選人 + 店家協調	時段 K-Means × 店家群聚	行為佐證確認
單評論帳號	生命週期 K-Means	廣泛；單獨精確度有限
爆發後消失模式	生命週期 K-Means	中等；加上店家群聚後增強
協調針對 (span < 7d)	店家群聚	精確度最高；人數最少


關鍵視覺化




分支一：聚類總覽



各群早晨發評比例



分支二：生命週期位置分佈



回頭驗證：24 小時指紋